Perfis dos candidatos
a deputado federal da Região Sul

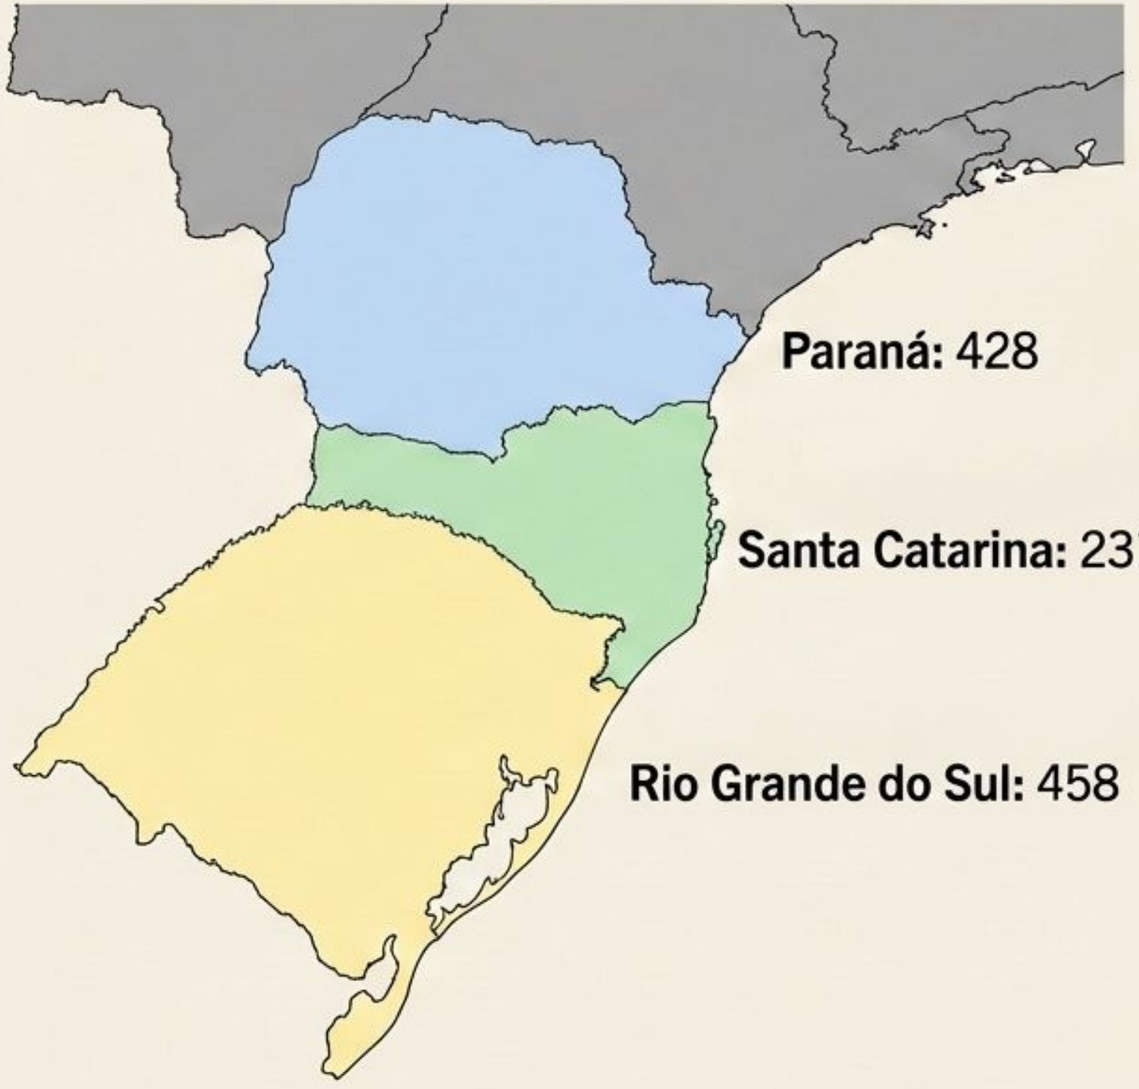
Mineração de dados eleitorais · Eleições 2026



Repositório GitHub

Flávia Rosa, Itagiba Neto, Bruno Presley, Leonardo Castro e Clara Cecília.
Pós-graduação em Data Science e Inteligência Artificial — Senac DF

O recorte da pesquisa: 1.117 candidaturas no Sul



O Objetivo

Identificar grupos de candidatos com características semelhantes e investigar padrões e casos atípicos nos dados.

A População

Analisamos 1.117 candidaturas a deputado federal nas eleições de 2026: 428 no Paraná, 231 em Santa Catarina e 458 no Rio Grande do Sul.
Fonte: dados do TSE.

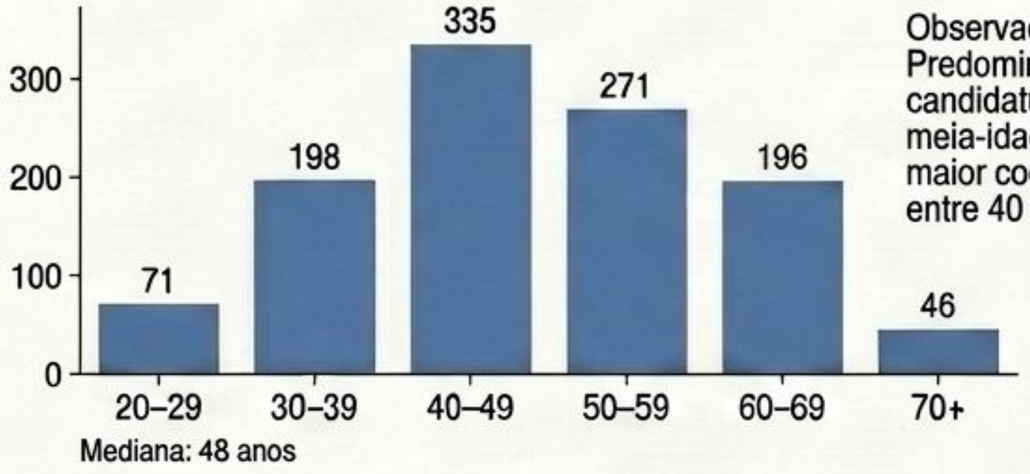
Variáveis da Clusterização

- Idade
- Tempo de estudo
- Bens declarados
- Despesas contratadas

Gemini Notebook

Análise descritiva das quatro variáveis

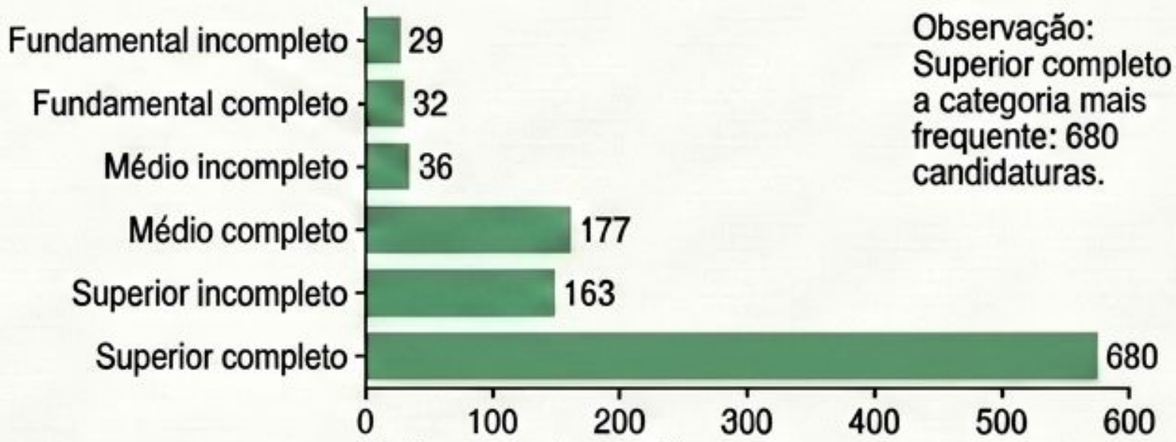
Idade (anos)



Observação: Predominam candidaturas de meia-idade; e maior cocentração entre 40 e 59 anos

Mediana: 48 anos

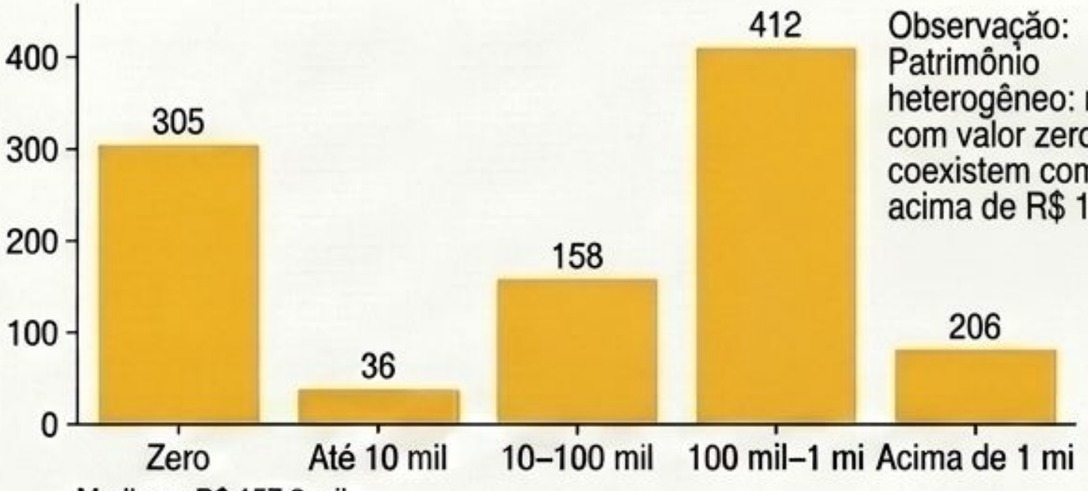
Escolaridade dos candidatos



Observação: Superior completo é a categoria mais frequente: 680 candidaturas.

Mediana: superior completo

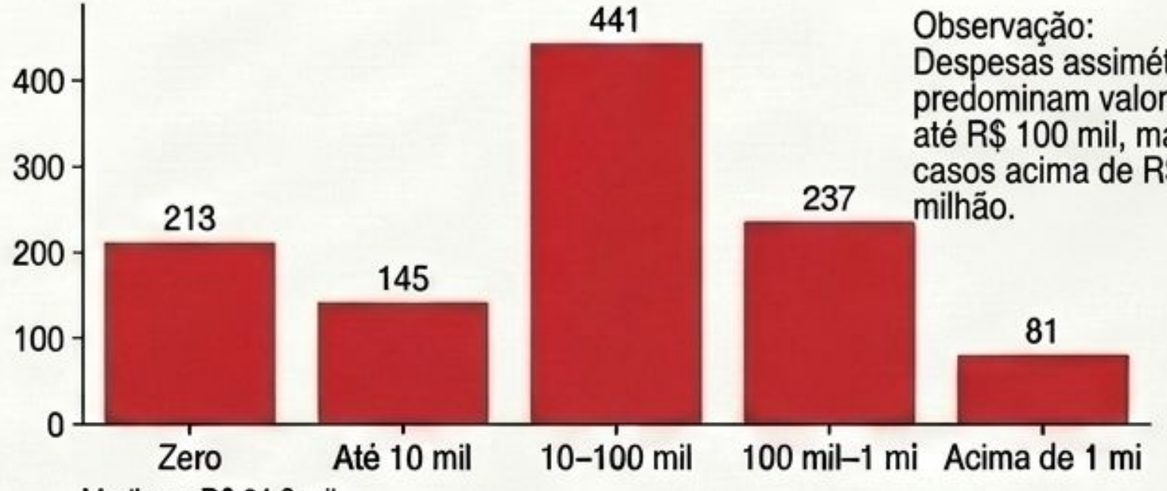
Bens declarados (R$)



Observação: Patrimônio heterogêneo: registros com valor zero coexistem com outros acima de R$ 1 milhão.

Mediana: R$ 157,8 mil

Despesas contratadas (R$)



Observação: Despesas assimétricas: predominam valores até R$ 100 mil, mas há casos acima de R$ 1 milhão.

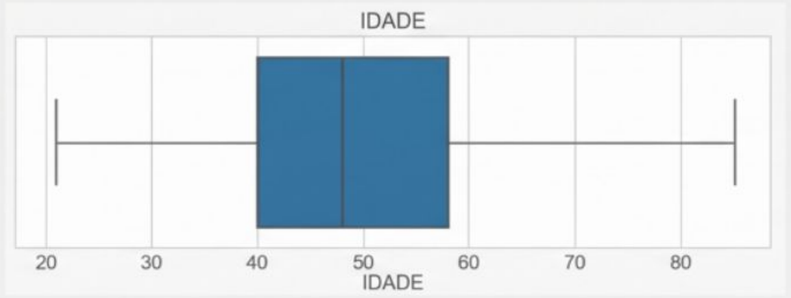
Mediana: R$ 34,3 mil

Fonte: TSE. Valores em R$; transformação logarítmica aplicada na clusterização.

Gemini Notebook

Análise Boxplot

ANÁLISE DA IDADE



Observações: Idade concentrada entre 40 e 60 anos (mediana em aprox. 48), com distribuição relativamente simétrica e sem outliers significativos.

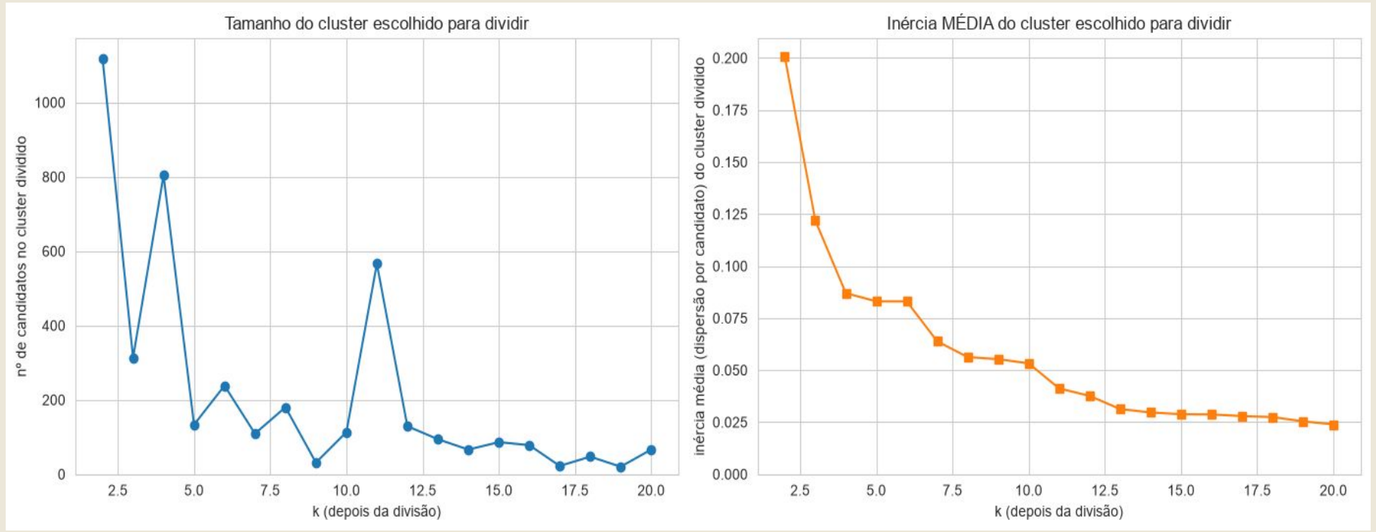
ANÁLISE DO TOTAL DE BENS

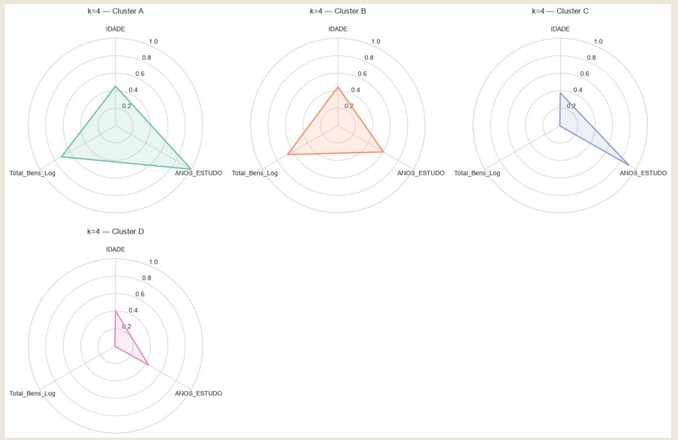


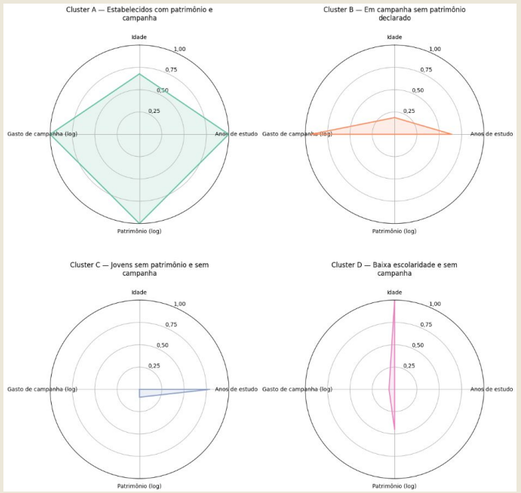
Observações: Extrema assimetria positiva. Média distorcida por valores discrepantes (outliers) altos, indo até 7.5e7. Necessário tratamento de dados antes da modelagem.

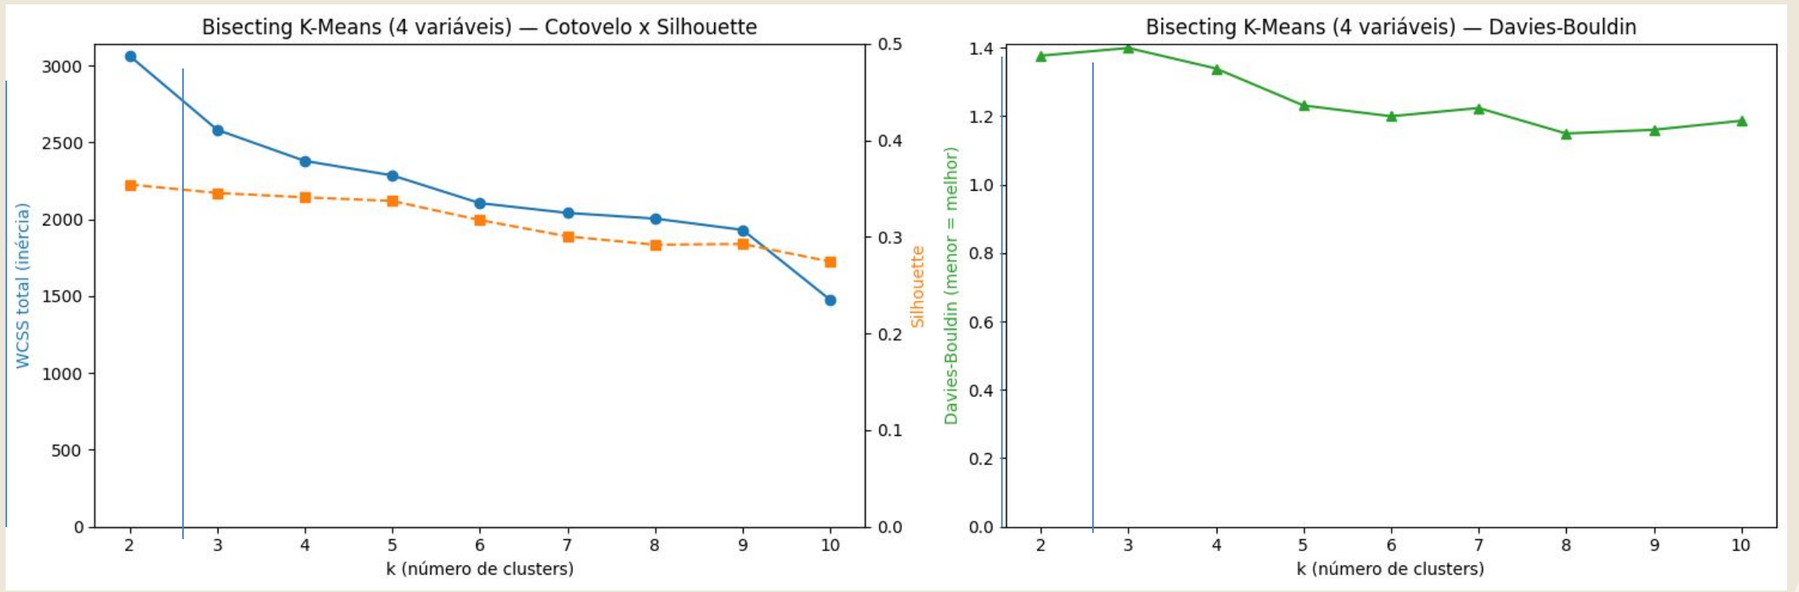
Bisecting K-Means: cotovelo, silhouette e Davies-Bouldin

Acima: exploração inicial (3 variáveis).
Abaixo: versão oficial (4 variáveis).









Valores de K testados: 2 a 10, com quatro métricas por partição

K	WCSS	Ganho de WCSS	Silhouette ↑	Davies-Bouldin ↓	Calinski-H. ↑	Menor cluster
2	3.062	—	0.354	1.376	512	405
3	2.581	481	0.345	1.399	407	183
4	2.379	202	0.341	1.339	326	89
5	2.285	94	0.337	1.231	266	39
6	2.104	180	0.317	1.199	250	39
7	2.041	64	0.300	1.223	220	39
8	2.004	37	0.292	1.149	195	12
9	1.931	73	0.293	1.160	182	12
10	1.476	455	0.275	1.186	249	12

K = 4 destacado. WCSS = soma das inércias de todos os clusters da partição; ↑ maior é melhor, ↓ menor é melhor. Cada partição foi reconstruída a partir do histórico de divisões e avaliada como um todo.

Perfil dos clusters para K = 3, 4 e 5

Silhouette – Bisecting K-Means, 4 variáveis (k=3): 0.345

cluster_bisecting	qtd	idade_media	anos_estudo_medio	patrimonio_mediano	pct_sem_bens	gasto_mediano	gasto_medio	pct_sem_gasto	pct_do_total
A	712	50.0	15.1	506199.4	0.1	66131.0	322018.8	6.3	63.7
B	222	44.6	12.8	0.0	86.9	23728.0	70807.8	0.0	19.9
C	183	47.9	11.3	0.0	60.7	0.0	418.7	91.8	16.4

K = 3

Silhouette – Bisecting K-Means, 4 variáveis (k=4): 0.341

cluster_bisecting	qtd	idade_media	anos_estudo_medio	patrimonio_mediano	pct_sem_bens	gasto_mediano	gasto_medio	pct_sem_gasto	pct_do_total
A	712	50.0	15.1	506199.4	0.1	66131.0	322018.8	6.3	63.7
B	222	44.6	12.8	0.0	86.9	23728.0	70807.8	0.0	19.9
C	94	42.5	13.7	0.0	76.6	0.0	4.0	94.7	8.4
D	89	53.7	8.6	16000.0	43.8	0.0	856.7	88.8	8.0

K = 4 ✓

Silhouette – Bisecting K-Means, 4 variáveis (k=5): 0.337

cluster_bisecting	qtd	idade_media	anos_estudo_medio	patrimonio_mediano	pct_sem_bens	gasto_mediano	gasto_medio	pct_sem_gasto	pct_do_total
A	712	50.0	15.1	506199.4	0.1	66131.0	322018.8	6.3	63.7
B	222	44.6	12.8	0.0	86.9	23728.0	70807.8	0.0	19.9
C	94	42.5	13.7	0.0	76.6	0.0	4.0	94.7	8.4
D	50	54.2	9.4	128400.0	0.0	0.0	1518.6	86.0	4.5
E	39	52.9	7.6	0.0	100.0	0.0	8.1	92.3	3.5

K = 5

Nomeando os clusters: o que cada perfil significa

Cluster A · 712 candidatos

Estabelecidos com patrimônio e campanha

Quase todos declaram bens (mediana R$ 506 mil) e já têm gasto de campanha.

Cluster B · 222 candidatos

Em campanha sem patrimônio declarado

Todos têm gasto, mas 87% não declaram bens. É o grupo mais feminino e menos branco;

Cluster C · 94 candidatos

Jovens sem patrimônio e sem campanha

95% sem despesa registrada e 77% sem bens. O que o define é a falta de patrimônio e de campanha.

Cluster D · 89 candidatos

Baixa escolaridade e sem campanha

Menor escolaridade (8,6 anos) e grupo mais velho (53,7 anos). 89% sem despesa registrada;

“Sem campanha” = sem despesa registrada até o extrato de 19/09/2026, com a campanha em andamento.

Rótulos oficiais dos clusters (Bisecting, k = 4)

Nomes atribuídos

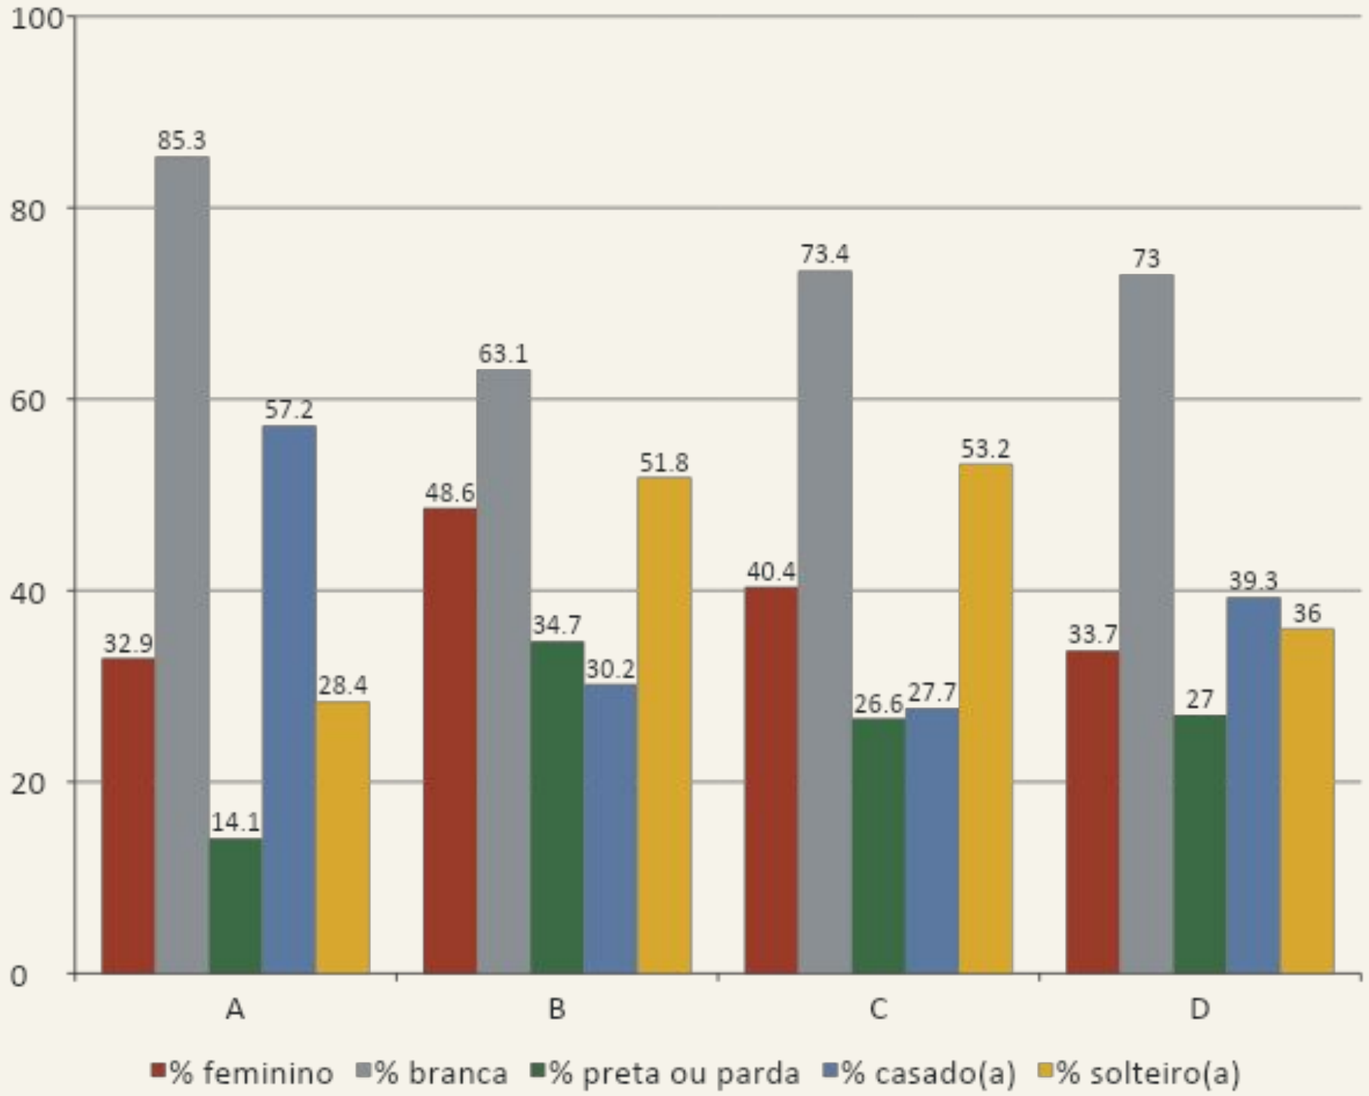
cluster_bisecting	nome_cluster_bisecting	
A	Estabelecidos com patrimônio e campanha	712
B	Em campanha sem patrimônio declarado	222
C	Jovens sem patrimônio e sem campanha	94
D	Baixa escolaridade e sem campanha	89

Ficha dos clusters (k = 4)

Silhouette — Bisecting K-Means, 4 variáveis (k=4): 0.341

cluster_bisecting	qtd	idade_media	anos_estudo_medio	patrimonio_mediano	pct_sem_bens	gasto_mediano	gasto_medio	pct_sem_gasto	pct_do_total
A	712	50.0	15.1	506199.4	0.1	66131.0	322018.8	6.3	63.7
B	222	44.6	12.8	0.0	86.9	23728.0	70807.8	0.0	19.9
C	94	42.5	13.7	0.0	76.6	0.0	4.0	94.7	8.4
D	89	53.7	8.6	16000.0	43.8	0.0	856.7	88.8	8.0

Visão geral das variáveis categóricas por cluster



Ocupações e partidos mais frequentes

A: empresário (14.0%); advogado (10.0%); vereador (8.6%); deputado (7.6%); outros (7.2%)

Partidos: PL (9.4%); PODE (9.1%); MDB (8.3%); NOVO (8.3%); REPUBLICANOS (7.6%)

B: outros (19.4%); empresário (14.0%); advogado (5.9%); estudante, bolsista, estagiário e assemelhados (4.1%); vereador (4.1%)

Partidos: PSOL (10.4%); MISSÃO (9.5%); PSD (7.7%); PSB (7.2%); MDB (7.2%)

C: “outros” 26%, estudante, empresário, advogado e administrador (6% cada).

DC (14.9%); DEMOCRATA (11.7%); MISSÃO (10.6%); AVANTE (10.6%); PSD (8.5%)

D: “outros” (21.3%); comerciante (11.2%); empresário (10.1%); dona de casa (9.0%); aposentado (exceto servidor público) (4.5%).

Partidos: DC (20.2%); DEMOCRATA (16.9%); AGIR (13.5%); SOLIDARIEDADE (6.7%); AVANTE (5.6%)

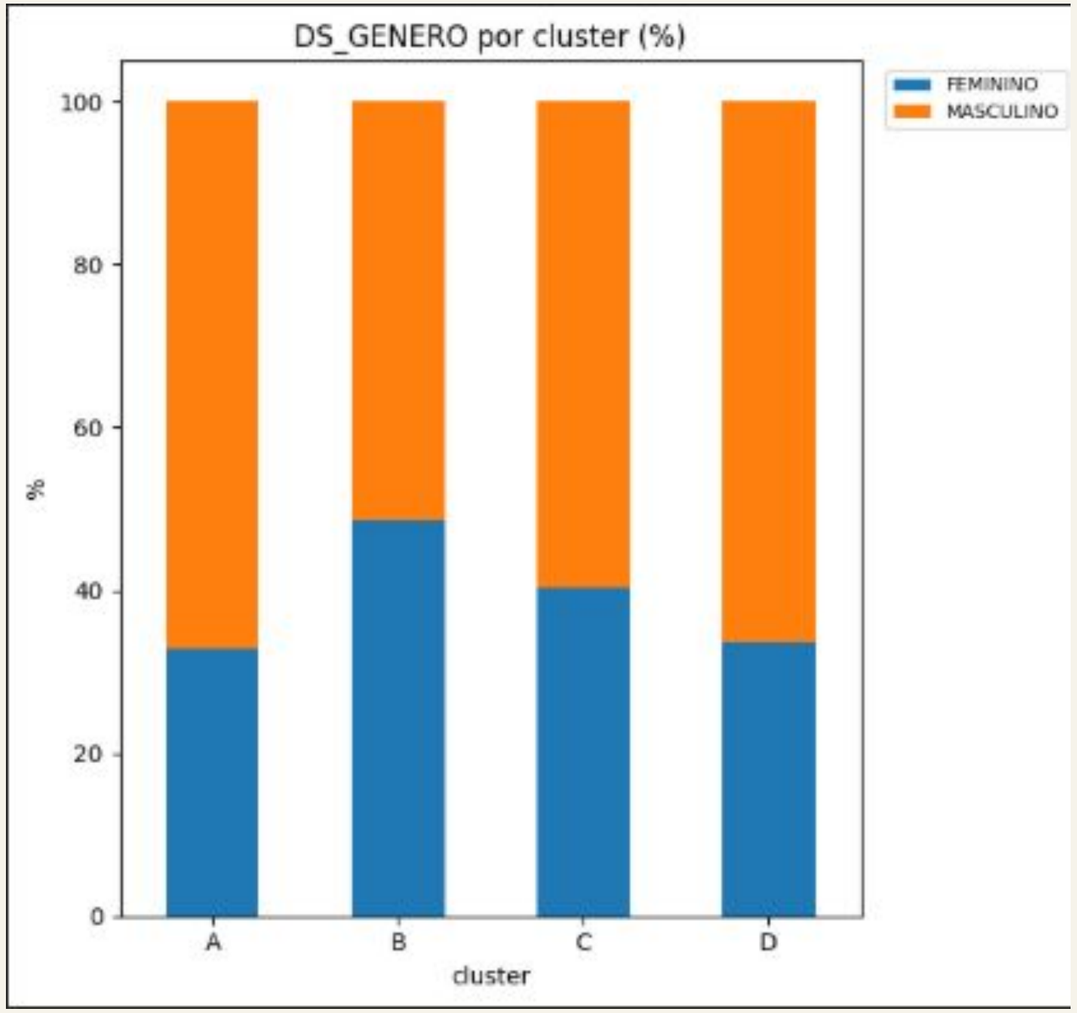
Achados:

A é o mais branco, masculino e casado;

B o mais feminino e menos branco;

C e D concentram solteiros (C) e mais velhos (D).

Sexo por cluster



DS_GENERO nome_cluster_bisecting	FEMININO	MASCULINO
Baixa escolaridade e sem campanha	33.7	66.3
Em campanha sem patrimônio declarado	48.6	51.4
Estabelecidos com patrimônio e campanha	32.9	67.1
Jovens sem patrimônio e sem campanha	40.4	59.6

A Estabelecidos com patrimônio e campanha

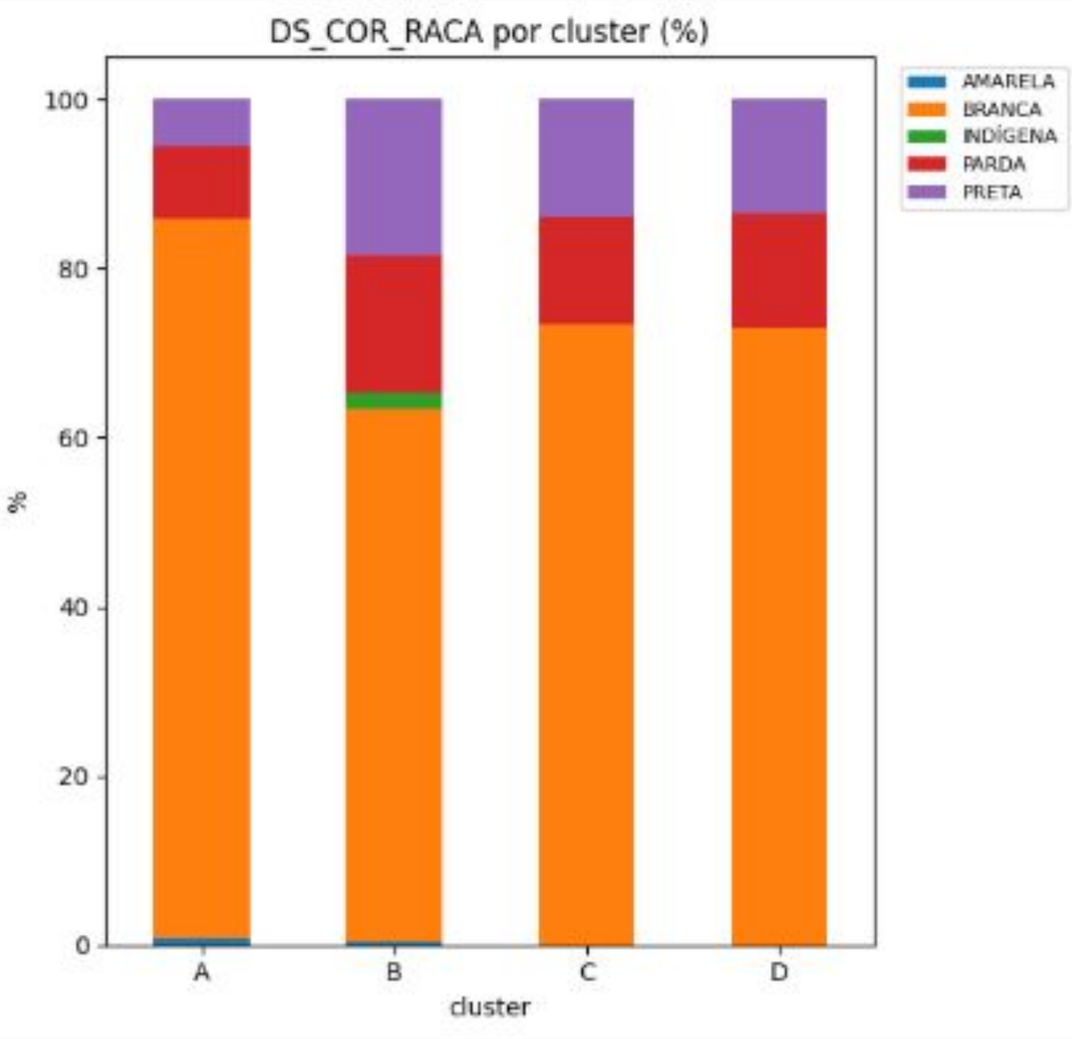
B Em campanha sem patrimônio declarado

C Jovens sem patrimônio e sem campanha

D Baixa escolaridade e sem campanha

Leitura: A é o mais masculino (67%); B é o mais equilibrado (49% feminino).

Raça/cor por cluster



DS_COR_RACA	AMARELA	BRANCA	INDÍGENA	PARDA	PRETA
nome_cluster_bisecting					
Baixa escolaridade e sem campanha	0.0	73.0	0.0	13.5	13.5
Em campanha sem patrimônio declarado	0.5	63.1	1.8	16.2	18.5
Estabelecidos com patrimônio e campanha	0.7	85.3	0.0	8.6	5.5
Jovens sem patrimônio e sem campanha	0.0	73.4	0.0	12.8	13.8

A Estabelecidos com patrimônio e campanha

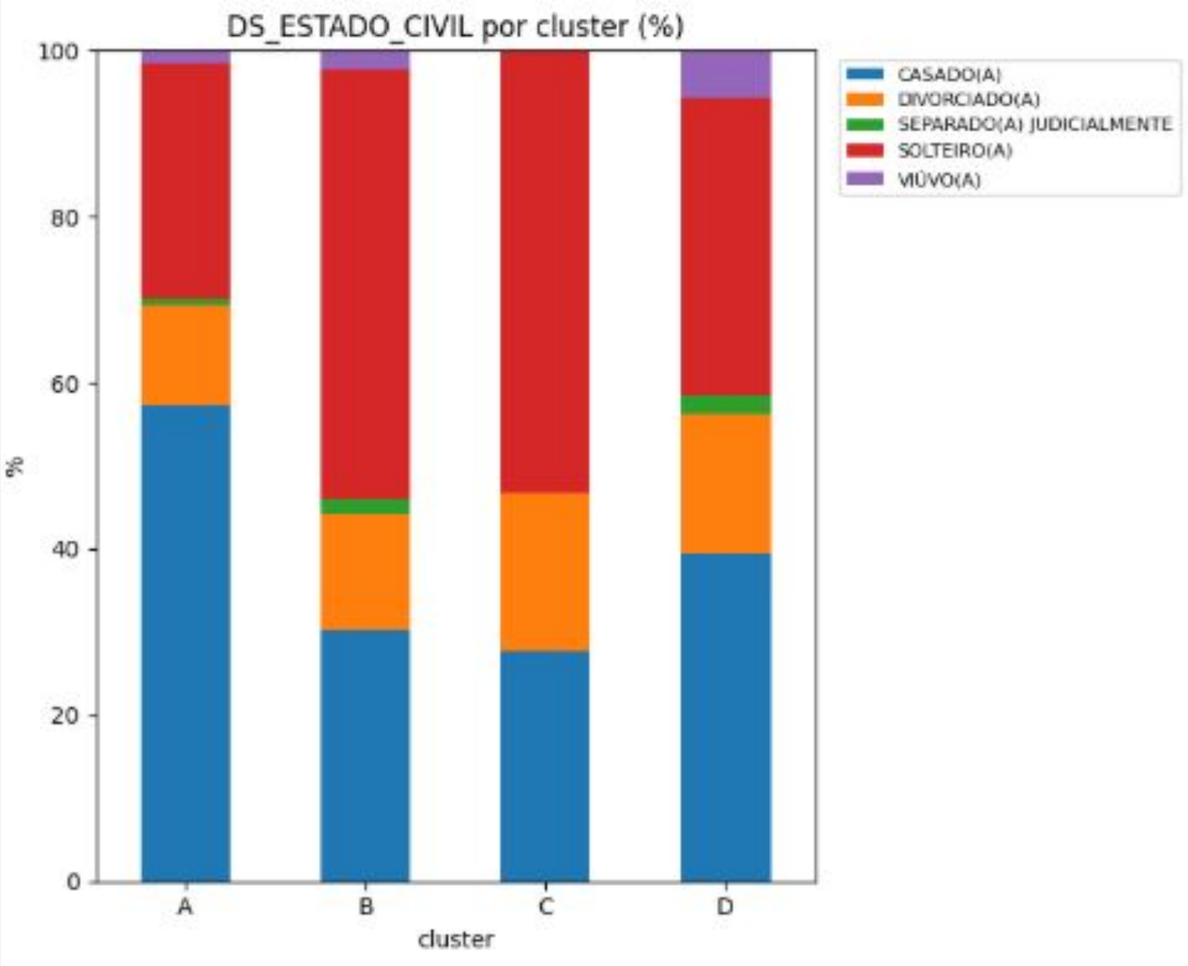
B Em campanha sem patrimônio declarado

C Jovens sem patrimônio e sem campanha

D Baixa escolaridade e sem campanha

Leitura: A tem 85% de brancos; B concentra mais pretos e pardos (35%).

Estado civil por cluster



DS_ESTADO_CIVIL nome_cluster_bisecting	CASADO(A)	DIVORCIADO(A)	SEPARADO(A) JUDICIALMENTE	SOLTEIRO(A)	VIÚVO(A)
Baixa escolaridade e sem campanha	39.3	16.9	2.2	36.0	5.6
Em campanha sem patrimônio declarado	30.2	14.0	1.8	51.8	2.3
Estabelecidos com patrimônio e campanha	57.2	12.2	0.7	28.4	1.5
Jovens sem patrimônio e sem campanha	27.7	19.1	0.0	53.2	0.0

A Estabelecidos com patrimônio e campanha

B Em campanha sem patrimônio declarado

C Jovens sem patrimônio e sem campanha

D Baixa escolaridade e sem campanha

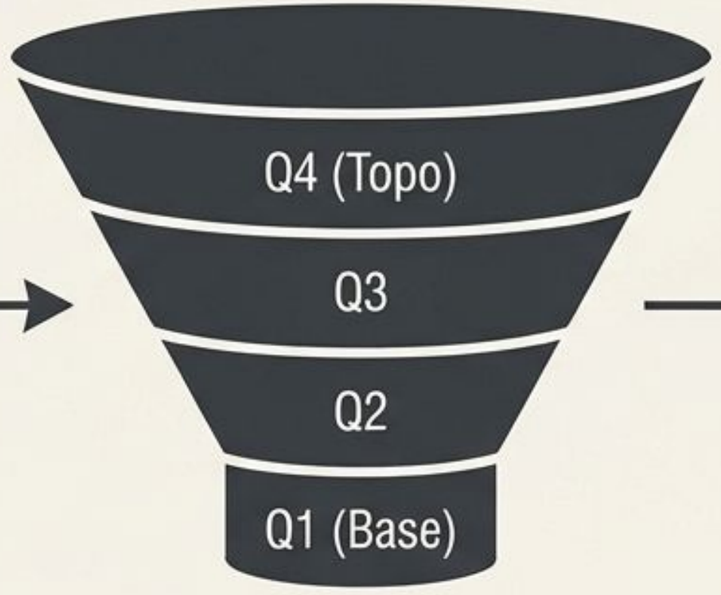
Leitura: A é o mais casado (57%); B e C concentram solteiros (52% e 53%).

Preparação Apriori: Transformando Grandezas em Categorias

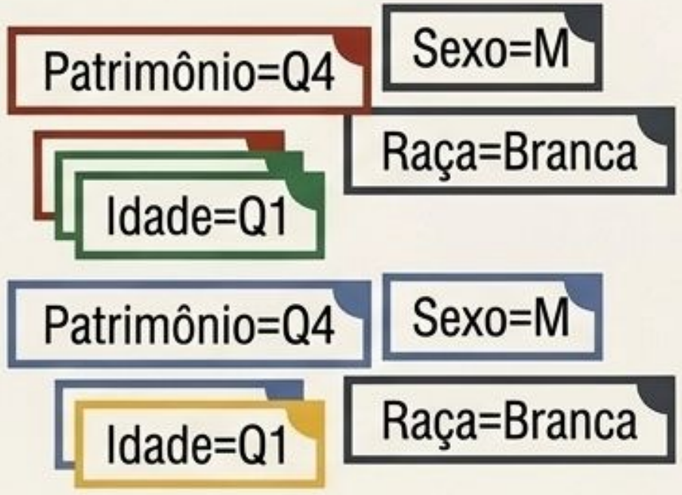
1. Dados Contínuos



2. Filtro de Quartis



3. Fusão Categórica



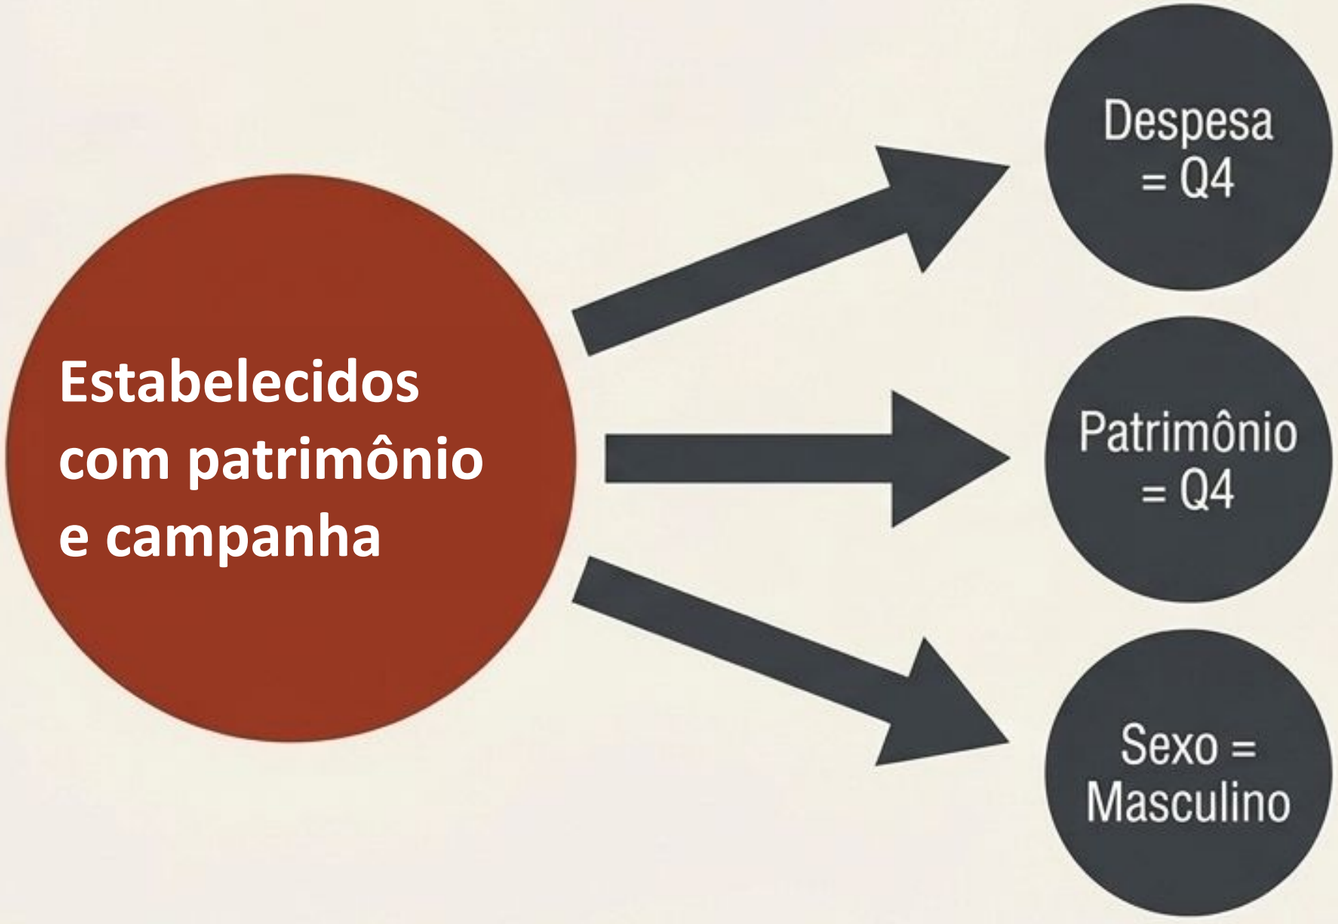
O Porquê: Esta transformação permite que o algoritmo Apriori leia variáveis matemáticas ('Patrimônio = Q4') da mesma forma que lê demografia ('Profissão = Advogado'), permitindo cruzar universos distintos e revelar regras de associação ocultas.

Gemini Notebook

link do site

A Anatomia do Perfil: Cluster no Antecedente

Se o candidato pertence à ‘Elite Tradicional’, o que o algoritmo garante sobre ele?



A Regra Encontrada:

Cluster A → Despesa Q4, Patrimônio Q4, Homem Branca

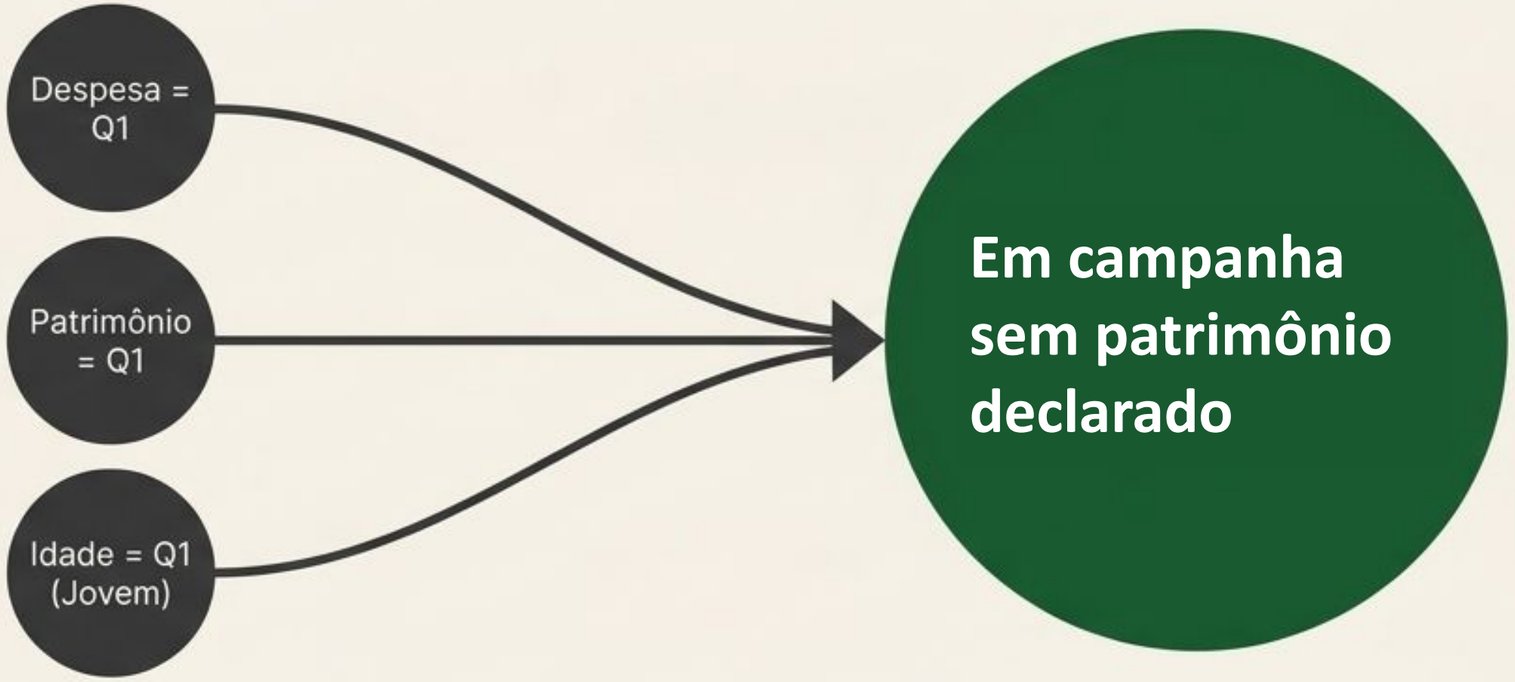
Confiança do Algoritmo: 94%

Interpretação: A presença neste cluster dita um viés quase absoluto para o topo da pirâmide financeira eleitoral. Isso valida perfeitamente o nome atribuído ao perfil, confirmando que o poder econômico monopoliza este grupo.

Gemini Notebook

A Receita do Perfil: Cluster no Consequente

Quais combinações de características jogam um candidato inevitavelmente para os “Outsiders”?



Link do site

A Regra (A Receita): Despesa Q1 + Patrimônio Q1 + Idade Q1 → Cluster B.

Confiança: 88%.

Validação do Nome: Esta regra confirma a hipótese inicial. O conjunto de baixíssimo orçamento associado à juventude resulta quase exclusivamente neste perfil, provando que a nomenclatura “Outsiders” é estatisticamente alicerçada pelas regras de associação de Apriori.

Gemini Notebook

Detecção de anomalias

Quem foge do padrão da base inteira e quem foge do padrão do próprio grupo?

Anomalia é sempre relativa a uma régua

1 · Anomalia global

O candidato foge do padrão dos **1.117** candidatos, qualquer que seja o cluster?

Isolation Forest nas 4 variáveis padronizadas na base inteira.

2 · Anomalia dentro do cluster

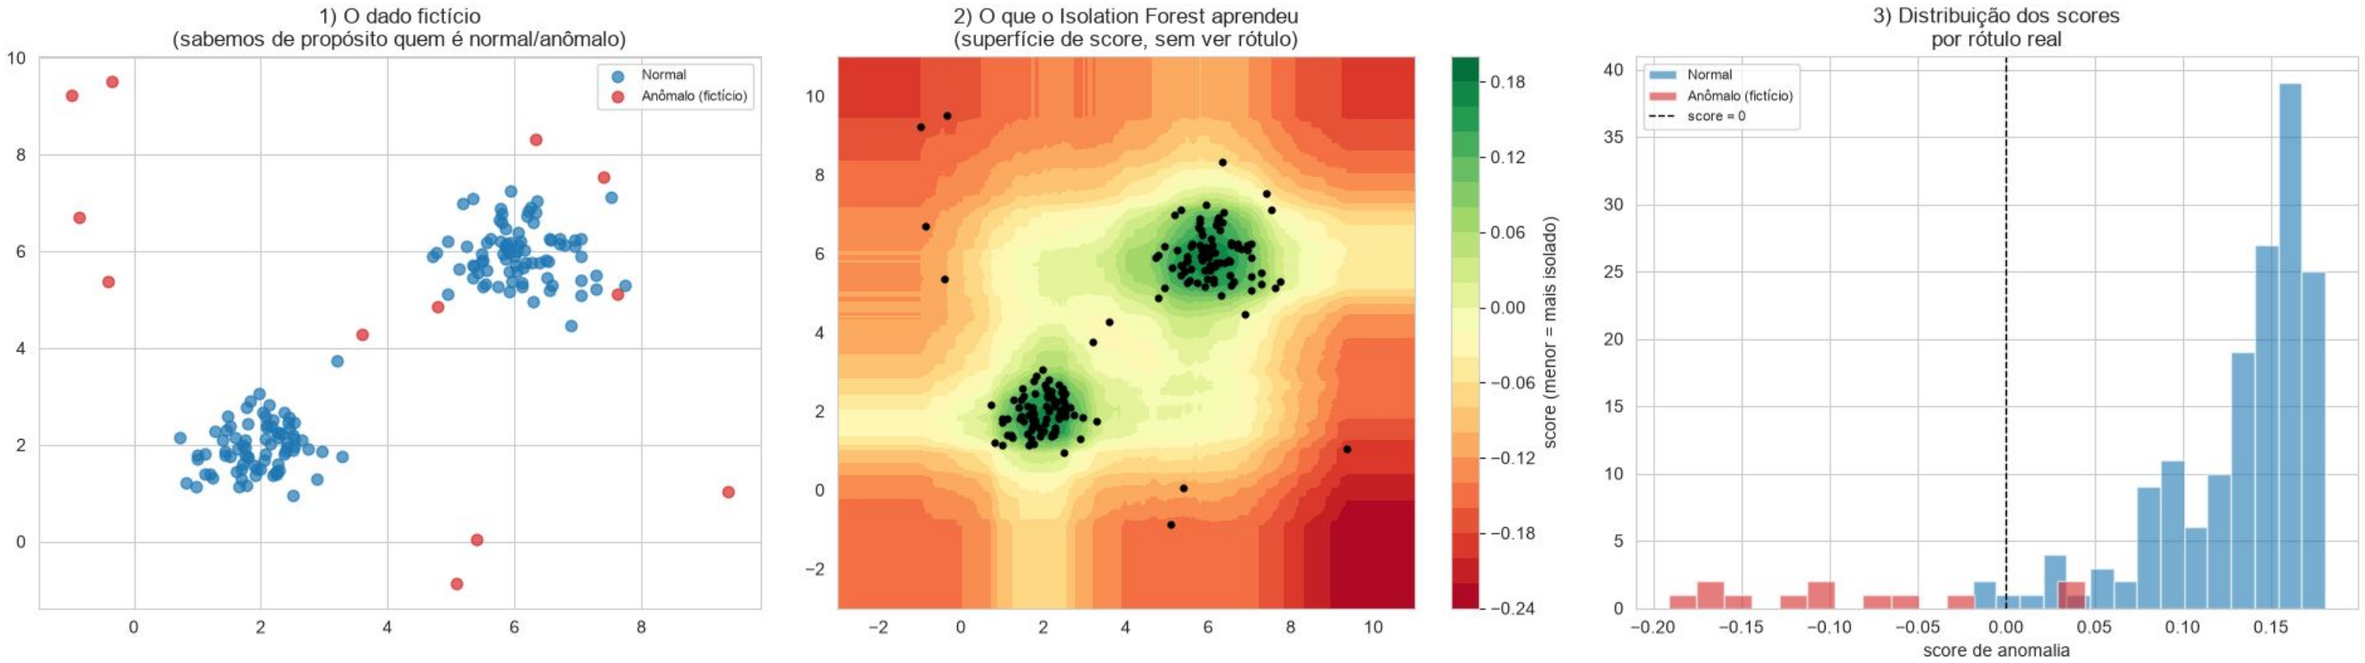
O candidato foge do padrão do **seu próprio grupo**?

Um Isolation Forest por cluster, com o StandardScaler **ajustado dentro de cada cluster**.

Por que padronizar de novo?

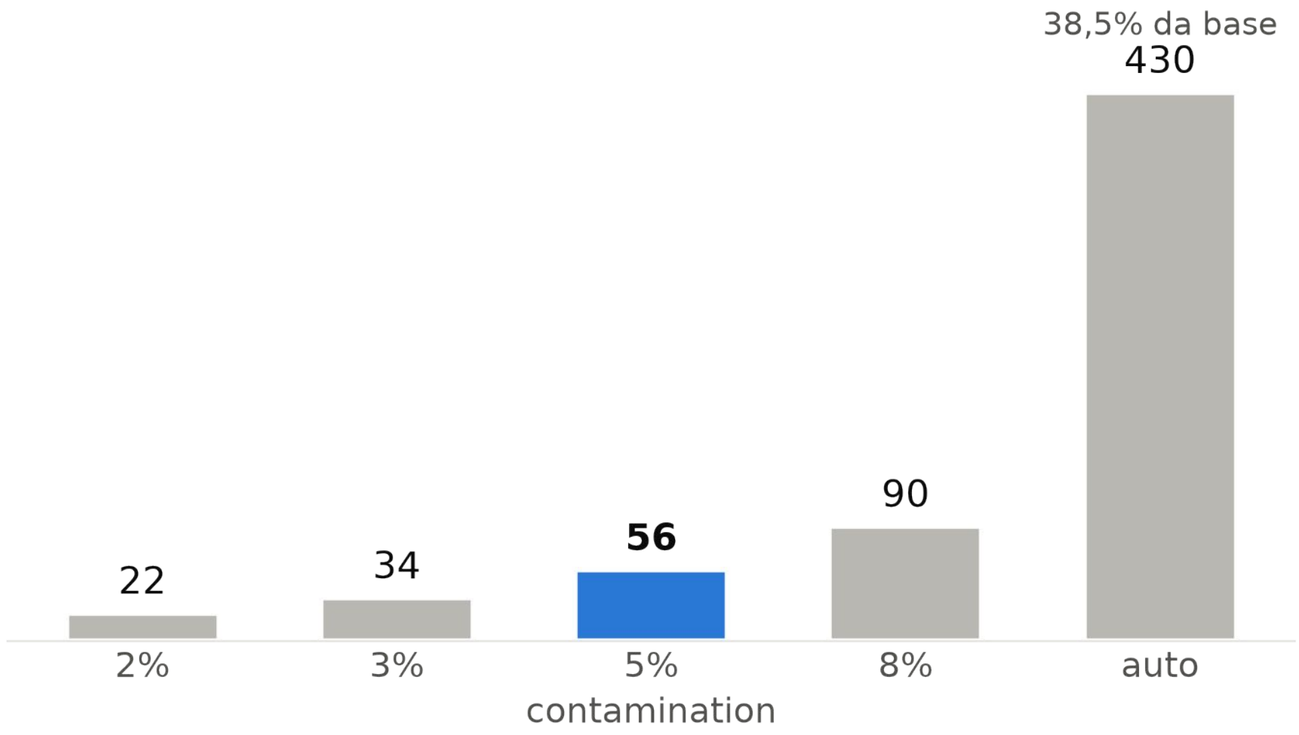
Com a escala global, a pergunta continuaria sendo "quem é extremo na base". Com a escala do grupo, vira "quem é estranho **para alguém deste grupo**".

Isolation Forest: o que é raro se isola com poucos cortes



- Cortes aleatórios em variáveis aleatórias: pontos em regiões vazias ficam sozinhos em poucos passos → **score baixo = mais anômalo**.
- Dados fictícios: a superfície fica verde sobre os grupos densos e vermelha nas bordas, **sem o modelo ver o rótulo**.
- 200 árvores · sem filtro prévio de outliers (em log, o IQR não removia ninguém).

Quanto marcar? contamination = 5%, ou 56 candidatos



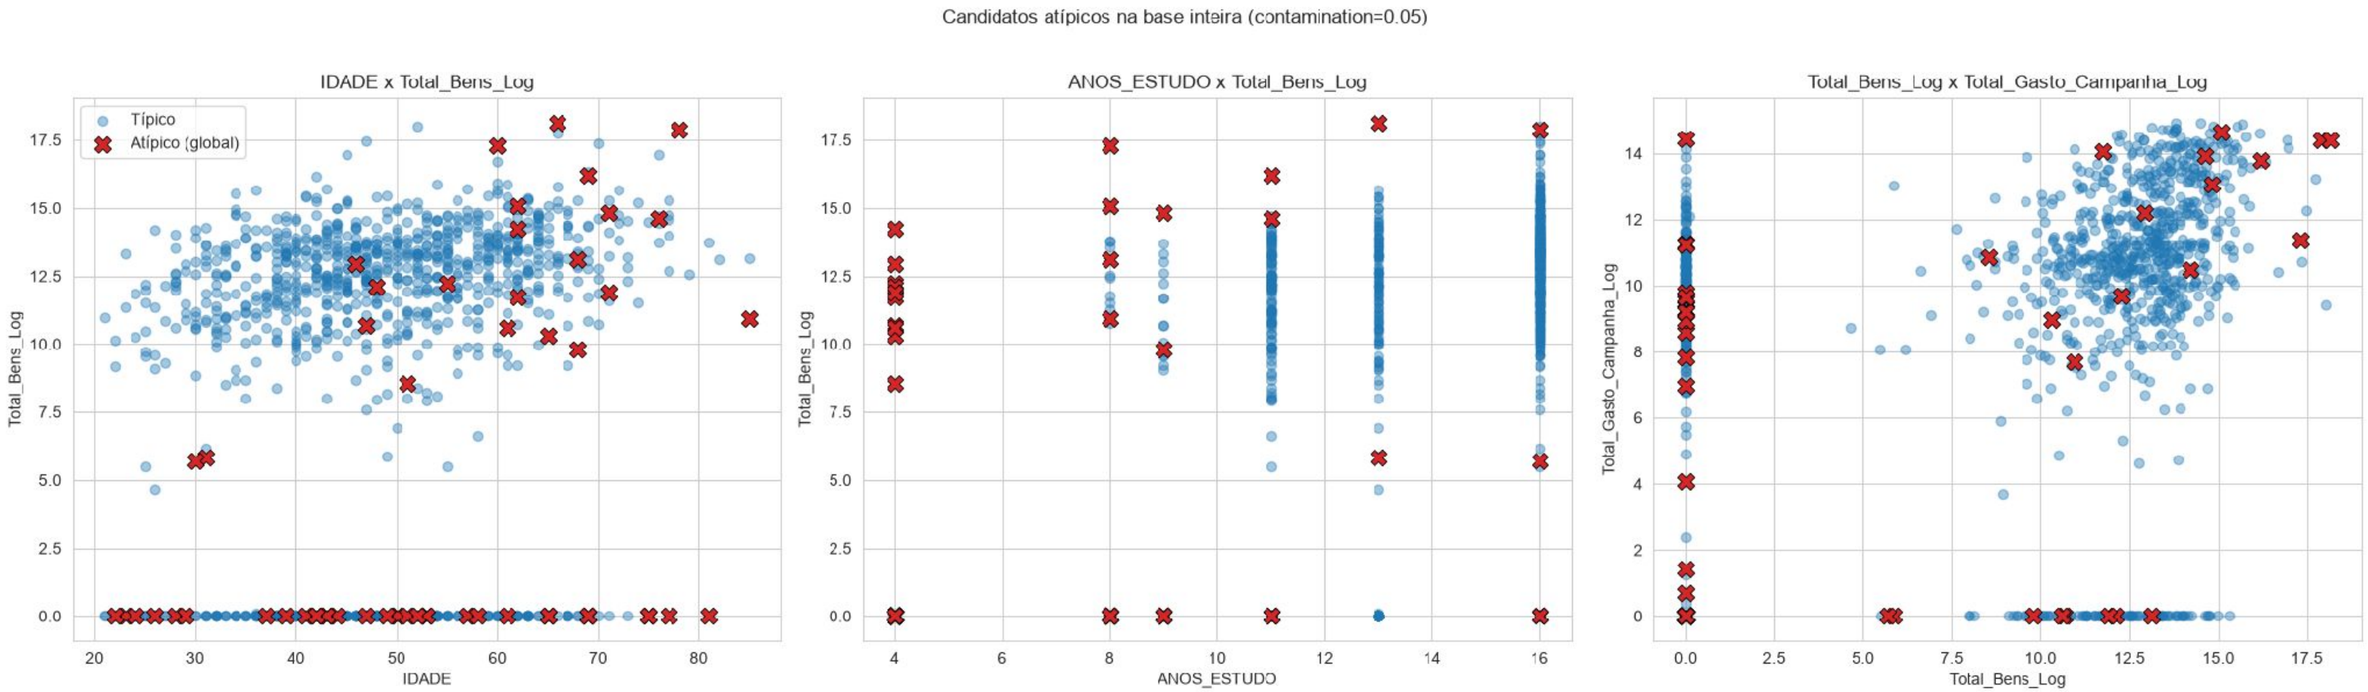
Candidatos marcados como atípicos em cada valor de contamination

Critério

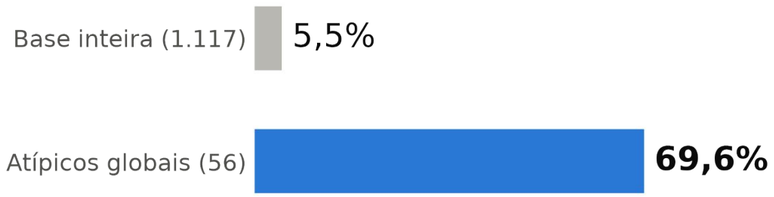
- **auto** marca 38,5% da base: implausível.
- **5%** gera uma lista que dá para examinar **um por um**.
- **Ranking estável:** os 22 de 2% e os 34 de 3% estão todos entre os 56 de 5%, e estes estão todos entre os 90 de 8%.
- Por cluster: também 5% (piso de 2), o que dá 36 · 12 · 5 · 5.

ANOMALIA GLOBAL

Na base inteira: 56 atípicos, e a baixa escolaridade domina



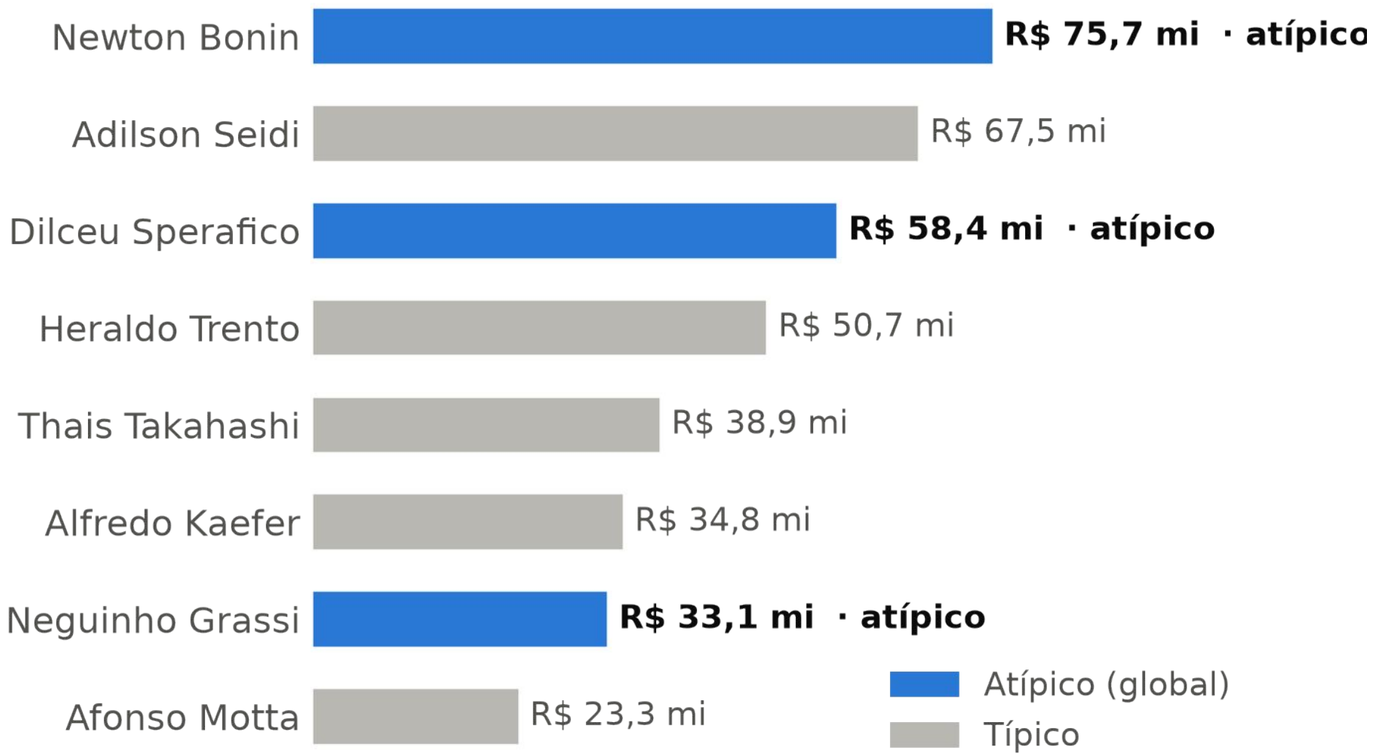
Com ensino fundamental, no máximo



- **Combinações raras:** nenhum bem declarado e R$ 1,86 mi de gasto (Jocelito Canto); R$ 33 mi em bens com fundamental completo (Neguinho Grassi).
- **Idades extremas:** 22 a 24 anos e 81 a 85 anos.
- **Grandes fortunas:** Newton Bonin (R$ 75,7 mi) e Dilceu Sperafico (R$ 58,4 mi).

Limite do método: combinações raras, não maiores valores

Os 8 maiores patrimônios declarados



Por que isso acontece

- Em **log**, R$ 50 mi e R$ 75 mi ficam próximos.
- Só 3 dos 8 maiores patrimônios são atípicos: os que combinam fortuna com **gasto alto** ou **baixa escolaridade**.
- **Nenhum** dos 6 maiores gastos (R$ 2,6 a 3,04 mi) é atípico.

Para achar os maiores valores basta ordenar. O Isolation Forest serve para achar **perfis improváveis**.

Dentro de cada grupo, o que é anômalo muda

A · Estabelecidos (36 atípicos)

- **Baixa escolaridade com patrimônio alto:** Neguinho Grassi, R$ 33 mi.
- **Gasto alto quase sem bens:** Amin Hannouche, sem bens e R$ 1,06 mi de gasto.
- **Bens sem nenhum gasto.**

B · Em campanha sem patrimônio (12)

- Quem **declarou bens** num grupo em que 87% não declaram (Solitário, R$ 413 mil).
- Quem gasta **muito acima da mediana** de R$ 24 mil: Jocelito Canto (R$ 1,86 mi) e Marcon (R$ 1,28 mi).

C · Nível superior sem campanha (5)

- Gastos **irrisórios, mas diferentes de zero**: R$ 0,50 a R$ 369.
- Parecem lançamentos de teste ou ajuste → **alerta de qualidade de dados**.

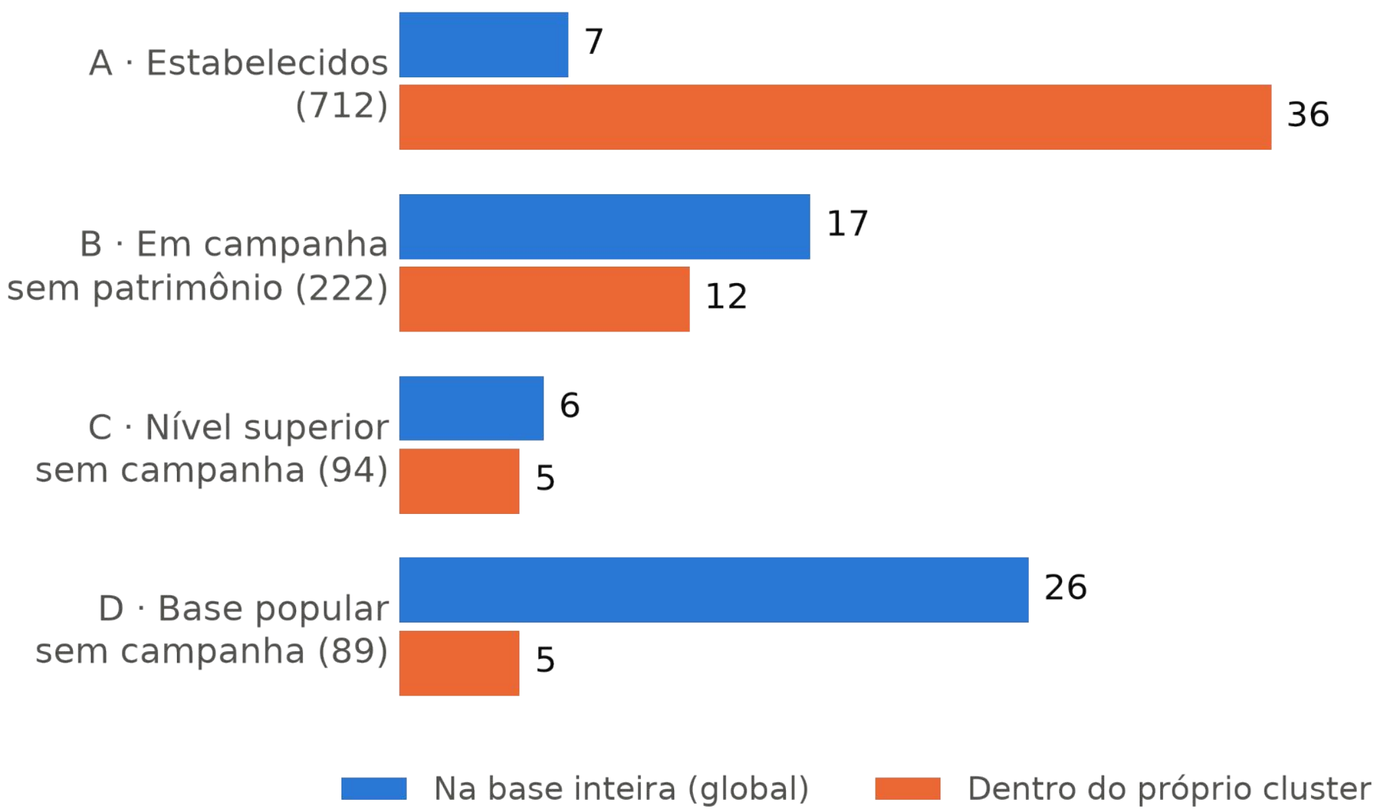
D · Base popular sem campanha (5)

- Quem **tem patrimônio** num grupo com mediana de R$ 16 mil: João Batista, eletricista, R$ 1,51 mi.
- A candidata **mais velha** da base: Ivoneide Duarte, 85 anos.

GLOBAL × DENTRO DO CLUSTER

41 candidatos só aparecem quando a régua é o próprio grupo

Atípicos por cluster, nas duas réguas



17

atípicos nos dois recortes

39

só na base inteira

41

só dentro do cluster

Leitura

- Global: **26 dos 56** atípicos estão na Base popular.
- Local: **36** estão nos Estabelecidos.
- As duas análises se **complementam**, e nenhuma substitui a outra.

Conclusões

O que aprendemos sobre os candidatos e sobre os métodos

Três mensagens

1

Patrimônio e campanha dividem os candidatos; a idade quase não pesa.

27% não declaram bens e 19% não tinham despesa, mas 222 fazem campanha ativa sem patrimônio declarado. As médias de idade dos grupos vão só de 42 a 54 anos.

2

Gênero, raça e partido aparecem nos perfis sem terem entrado no modelo.

O grupo em campanha sem patrimônio é o mais feminino e o menos branco (PRETA → B, lift 2,0; PSOL → B, 2,1). Os partidos grandes, de todo o espectro, concentram-se nos Estabelecidos.

3

O que é anomalia depende da régua.

Na base inteira o atípico é, sobretudo, a baixa escolaridade. Dentro dos grupos ele muda, e 41 candidatos só aparecem nessa análise. Parte das anomalias é ruído de prestação de contas.

O que era esperado e o que foi novo

Confirmou o esperado

- Maioria de homens, brancos, com nível superior e com patrimônio.
- O grupo com patrimônio concentra empresários e políticos com mandato.
- Partidos grandes associados a campanhas estruturadas.

Foi novo

- **27%** declararam patrimônio zero.
- O gasto só tem correlação moderada com o patrimônio (r = 0,37) e separa os grupos sem bens.
- O **recorte racial** aparece forte no grupo sem patrimônio, sem cor/raça no modelo.
- Parte das anomalias locais é **ruído de dados** (R$ 0,50 a R$ 369).
- As **maiores fortunas** nem sempre são anomalias.

Contribuição, limitações e próximos passos

Principal contribuição

Entre os candidatos a Deputado Federal no Sul, a desigualdade mais visível é de **patrimônio combinado com estrutura de campanha e escolaridade**, e não de idade. Ela vem acompanhada de recortes de gênero, raça e partido, e os casos que merecem investigação **dependem da régua** usada.

Limitações

- Gasto **parcial**: despesas contratadas até 19/09/2026.
- "Sem bens" pode ser declaração incompleta.
- O log comprime os valores altos.
- Clusters C e D pequenos: só 5 atípicos locais em cada.

Próximos passos

- Cruzar perfis e anomalias com o **resultado da eleição** (DS_SIT_TOT_TURNO) depois de 04/10.
- Repetir com a **prestação de contas final**.
- Checar os atípicos locais junto ao TSE, como **auditoria de dados**.

Obrigado!

Perguntas?

